

Pemrosesan Sinyal Jantung untuk Myocardial Infarction

Ira Puspasari
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung
Bandung, Indonesia
33221050@std.stei.itb.ac.id

Promotor: Tati Latifah Erawati R.
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung
Bandung, Indonesia
tmengko@itb.ac.id

Ko-Promotor: Agung Wahyu S.
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung
Bandung, Indonesia
awsetiawan@staff.stei.itb.ac.id

Abstract—Penderita penyakit jantung semakin hari bertambah secara global di dunia. Hal ini tidak hanya dikarenakan penyakit jantung bawaan, melainkan juga karena faktor gaya hidup yang mengakibatkan terjadinya kelainan pada jantung. Banyak kejadian kematian mendadak yang dikarenakan serangan jantung atau Heart Attack disebut juga Myocardial Infarction (MI). Diagnosis dini akan membantu pasien mendapatkan penanganan yang tepat dan mengurangi prevalensi kematian. Identifikasi MI membutuhkan proses yang *real time* karena penyakit ini memiliki “golden hour”, setelah melewati masa ini otot jantung akan mati. Saat ini telah banyak penelitian tentang MI, namun menggunakan data sinyal Electrocardiogram (ECG). Penelitian ini mengusulkan eksplorasi sinyal Phonocardiogram (PCG) untuk klasifikasi sinyal suara jantung saat terjadi serangan jantung. Tanpa bertujuan menggantikan fungsi dokter, penelitian ini mengembangkan proses auskultasi yang menghasilkan proses klasifikasi untuk membantu dokter dalam mengambil keputusan tindakan pada pasien. Artikel ini berisi kajian dari akuisisi data PCG, pra pemrosesan sinyal, ekstraksi dan reduksi ciri, sampai dengan klasifikasi untuk membedakan sinyal jantung normal dan MI.

Keywords—jantung, klasifikasi, myocardial infarction, deep learning

I. PENDAHULUAN

Menurut laporan Organisasi Kesehatan Dunia (WHO) 2014 kematian akibat Penyakit Jantung Koroner (PJK) di Bangladesh mencapai 6,96% dari total kematian. Mendeteksi serangan jantung tepat waktu sangat penting karena keterlambatan dalam memprediksi dapat menyebabkan kerusakan parah pada otot jantung, yang disebut miokardium yang menyebabkan morbiditas dan mortalitas [1]. Sejumlah 17 juta orang meninggal dikarenakan penyakit jantung, berdasarkan Riset Kesehatan Dasar 2018, laporan kesehatan nasional Indonesia 13.2% di atas umur 54 tahun lebih dari 300.000 menderita penyakit jantung, dan sekitar 6.4% adalah dari bayi sampai umur 54 tahun, penyakit jantung ini bisa menyerang pada berbagai umur [2].

Berdasarkan Survei Pemeriksaan Kesehatan dan Gizi Nasional (NHANES) data Tahun 2009-2021, prevalensi MI (Myocardial Infarction) adalah 2,8% pada orang dewasa AS yang lebih besar dari 20 tahun. Perluasan MI sangat cepat dan jika tidak didiagnosis dan diobati pada waktunya, dapat merusak struktur miokard dan fungsi ventrikel kiri atau Left Ventricle (LV), karena kontraktilitas miokard menyebabkan kontraksi LV. Proyeksi menunjukkan bahwa pada tahun 2030, PJK akan meningkat sekitar 18% dari tahun 2015

dengan estimasi 15,4 juta. Dengan demikian, lebih awal dan lebih cepat insiden MI diidentifikasi, sangat berpengaruh terhadap kontraktilitas dan fungsi LV, menyebabkan kelangsungan hidup yang lebih baik [3].

Terdapat beberapa jenis MI diantaranya adalah non ST-Elevation Myocardial Infarction (NSTEMI) dan ST-Elevation Myocardial Infarction (STEMI). NSTEMI merupakan jenis serangan jantung yang terjadi ketika salah satu atau lebih pembuluh darah jantung mengalami penyumbatan sebagian, sehingga menyebabkan otot jantung hanya mendapatkan sedikit pasokan darah dan nutrisi. STEMI merupakan jenis serangan jantung yang terjadi ketika salah satu atau lebih dari satu pembuluh darah jantung tersumbat total secara tiba-tiba. Akibatnya, otot jantung tidak mendapatkan pasokan darah dan nutrisi, sehingga akan rusak dan mati. Meskipun, kondisi aliran darah keduanya berbeda, tetapi orang yang mengalami STEMI dan NSTEMI biasanya menunjukkan gejala yang mirip, sehingga sulit dibedakan. Cara membedakan seseorang mengalami NSTEMI atau STEMI adalah dengan EKG (Elektrokardiogram). NSTEMI memang tidak separah STEMI, tetapi NSTEMI tetap berbahaya dan berisiko pada kematian.

STEMI adalah penyebab utama kematian di negara berkembang [4]. Selain itu, MI juga sering disebut sebagai serangan jantung mendadak, karena pasien tidak menyadari bahwa menderita MI sampai serangan jantung terjadi. Menurut American Heart Association, diperkirakan bahwa 750.000 orang Amerika mengalami serangan jantung setiap tahun. Dari 750.000 orang Amerika ini, 210.000 mengalami serangan jantung berulang, menyebabkan 72% dari otot jantung pasien rusak. Akibatnya, tingkat kematian MI sangat tinggi. Oleh karena itu, diagnosis dini MI akan membantu pasien untuk mendapatkan perawatan tepat waktu, dan karenanya mengurangi prevalensi kematian [5]. MI umumnya dikenal sebagai serangan jantung, dan angina Pectoris, atau nyeri dada tercakup dalam PJK. Sebuah penyumbatan tiba-tiba arteri koroner, umumnya karena bekuan darah menghasilkan serangan jantung [6].

Sekitar 15 juta pasien per tahun terdapat dalam keadaan darurat Kamar (UGD) dengan nyeri dada atau gejala sugestif lainnya dari MI. Identifikasi MI yang cepat sebelum “golden hour” sangat penting untuk inisiasi yang efektif dalam perawatan dan manajemen medis. MI terjadi ketika penyempitan di arteri atau penyumbatan tiba-tiba dari bekuan darah memotong pasokan nutrisi dan oksigen ke otot jantung. Golden Hour adalah waktu yang kritis karena Otot jantung mulai mati dalam waktu 80-90 menit setelah berhenti

mendapatkan darah, dan dalam waktu enam jam hampir semua bagian jantung yang terkena mengalami kerusakan permanen [7]. MI akut dengan angina yang tidak stabil dianggap sebagai sindrom akut MI, meliputi: NSTEMI dan STEMI. Perbedaan antara NSTEMI dan STEMI sangat penting karena strategi pengobatan berbeda untuk kedua entitas ini [8].

Pemeriksaan penyakit jantung di Indonesia, terbagi menjadi tiga: menggunakan stetoskop, perekaman sinyal suara jantung, yaitu Phonocardiogram (PCG), peralatan yang digunakan pada proses ini adalah stetoskop baik akustik maupun digital, perekaman aktivitas elektrik jantung, yaitu Electrocardiogram (ECG), peralatan yang digunakan pada proses perekaman adalah elektroda, dan Echocardiogram (Echo) yang memanfaatkan proses USG untuk mengetahui keadaan jantung secara fisik. Pemeriksaan ini membutuhkan dana yang tidak sedikit, tidak mudah karena harus dilakukan oleh dokter ahli, dan hasilnya masih berupa dalam bentuk File dan kertas, belum ada database serta kemampuan untuk dikirim secara jarak jauh. Pemeriksaan menggunakan PCG membutuhkan pengalaman khususnya pendengaran yang bisa dipengaruhi oleh subjektivitas. Pemeriksaan ECG membutuhkan waktu yang lama dan harus menunggu bacaan hasil oleh dokter ahli jantung. Pemeriksaan yang paling detail adalah menggunakan Echocardiogram akan tetapi membutuhkan biaya yang cukup mahal. Hal ini akan mempengaruhi keadaan pasien, jika kondisi pasien masuk ke IGD dalam keadaan kritis dengan ciri-ciri penyakit jantung, namun belum diketahui penyebabnya. Langkah awal pasien akan diperiksa oleh dokter umum yang sedang ada, jika terdapat suara mencurigakan akan dilanjutkan ke pemeriksaan ECG. Hal ini memiliki kelemahan karena belum tentu setiap dokter umum bisa membaca hasil ECG. Sedangkan jika ternyata pasien ini adalah pasien yang terkena serangan jantung, maka kecepatan dan ketepatan penanganan akan sangat berpengaruh. Selanjutnya jika hasil ECG terdapat kecurigaan, pasien akan masuk ke laboratorium untuk dilakukan pemeriksaan lebih lanjut terkait MI dan jenisnya. Pemeriksaan laboratorium ini membutuhkan biaya yang mahal, dengan waktu tunggu selama satu jam. Jika tidak dilakukan pemeriksaan laboratorium, maka akan berdampak pada kesalahan penanganan, dan jika ternyata bukan pasien serangan jantung kemudian diberikan obat serangan jantung akan mengakibatkan kematian. Selain itu terdapat kelangkaan reagen di laboratorium, sering terjadi di beberapa Rumah Sakit.

Oleh karena itu dibutuhkan pemeriksaan yang cepat, saat ini pemeriksaan yang cepat adalah menggunakan stetoskop akan tetapi kondisi stetoskop klasik saat ini hanya bisa digunakan untuk mendengarkan hasil pemeriksaan. Stetoskop elektronik yang berkembang saat ini antara lain Littmann dan Thinklabs. Kedua stetoskop ini mampu merekam dan memiliki software yang mampu digunakan untuk menggambarkan hasil perekaman. Thinklabs telah disesuaikan stetoskop elektronik yang juga bekerja dengan aplikasi smartphone dan perangkat lunak aplikasi desktop. Namun, perangkat lunak hanya merekam, menampilkan, dan berbagi suara jantung. Perangkat lunak komputer dan smartphone tidak menyediakan analitik untuk atau menentukan jenis suara jantung [9]. Saat ini, proses filter ambient telah tersedia dalam stetoskop elektronik, dengan

3M Littmann 3000 dan Thinklabs ds32a menawarkan metode untuk menghilangkan kebisingan lingkungan [10].

Untuk memiliki sistem klasifikasi diperlukan tambahan kecerdasan buatan pada sistem stetoskop tersebut. Beberapa penelitian awal tentang pengolahan sinyal PCG untuk deteksi ketidaknormalan sinyal jantung antara lain: Hasil penerapan ekstraksi ciri dengan menggunakan metode Ensemble, serta integrasi dengan deep learning menggunakan 124 time-frekuensi fitur, menghasilkan klasifikasi untuk pengenalan sinyal abnormal dengan tingkat akurasi 0.8602 (sensitivitas 0.9424 dan spesifisitas 0.7781. Hasil sensitivitas tinggi ini memberikan rekomendasi untuk proses screening [11]. Penerapan metode RNN, LSTM, GRU, B-RNN, B-LSTM dan CNN dengan memanfaatkan 3 layer Deep learning pada Physionet Dataset, CNN memberikan hasil terbaik yaitu menghasilkan akurasi 80%, hal ini dikarenakan terdapat proses mekanisme filtering dengan FFT Butterworth filter [12]. Telah dilakukan penelitian yang terdiri dari 23 subjek dengan 5 subjek normal, 6 subjek Aortic Stenosis, 12 Tricuspid Regurgitation. Pada penelitian Diagnosis abnormal sinyal suara jantung pada pemrosesan sinyal PCG, dengan mengembangkan metode SVM, didapatkan akurasi, 96.2% [13].

Saat ini juga terdapat eksplorasi tentang deteksi sinyal ECG untuk mengenali deteksi sinyal jantung pada pasien MI, antara lain: Penerapan ANN dan pengembangannya berupa aplikasi deep convolutional neural network untuk deteksi otomatis MI menggunakan sinyal ECG: telah diterapkan metode kecerdasan buatan (ANN) sebelum dikembangkan ke arah Deep Learning yaitu pada penelitian [14], klasifikasi MI melalui analisis multi resolusi wavelet dari ECG. Karena kekurangan data, kinerja metode ANN relatif rendah. Implementasi sistem CAD akan meningkatkan objektivitas dan kecepatan diagnosis MI, diagnosis secara otomatis menggunakan 11-layer deep CNN, akurasi, sensitivitas dan spesifisitas 93.53%, 93.71% dan 92.83% untuk sinyal ECG dengan noise dan akurasi, sensitivitas dan spesifisitas 95.22%, 95.49%, and 94.19% tanpa noise [5]. Elevasi segmen-ST memiliki spesifisitas sebesar 90%, dan sensitivitas 45% untuk diagnosis myocardial infarction. Diagnosis MI dari sinyal ECG lebih sulit saat terjadi blok penyumbatan kiri karena menyerupai perubahan STEMI. Elevasi segmen ST dengan QRS kompleks menunjukkan bahwa MI lebih dari 5 mm segmen ST [8].

Deteksi Acute Myocardial Infarction (AMI) menggunakan Deep Learning-Enabled Electrocardiograms, penelitian ini menghasilkan nilai presisi, sensitivitas, specificity dan nilai F1 model deep learning untuk diagnosis AMI 0.827, 0.824, 0.950 dan 0.825 untuk data training, 0.789, 0.818, 0.913, dan 0.803, untuk data validasi, dan 0.830, 0.951, 0.951, and 0.886, untuk data testing. AUC untuk diagnosis lokasi AMI dari LMI, IMI, ASMI, AMI, ALMI sebesar 0.969 (95% CI: 0.959–0.979), 0.973 (95% CI: 0.962–0.978), 0.987 (95% CI: 0.963–0.989), 0.961 (95% CI: 0.956–0.989), dan 0.996 (95% CI: 0.957–0.997) [15].

Dikarenakan butuh real time, maka pada penelitian ini akan mengeksplorasi CNN 1 D dengan proses komputasi yang cepat. Penelitian tentang percepatan proses komputasi antara lain: Metode yang diusulkan dalam [16] telah mencapai akurasi rata-rata tertinggi (99% untuk Ventricular Ectopic Beats (VEB) dan 97,6% untuk Supraventricular Ectopic Beats (SVEB)) pada deteksi aritmia dengan

kompleksitas komputasi minimal. Penelitian tentang deteksi anomali phonocardiogram menggunakan adaptif Convolutional Neural Networks 1D, yang melakukan improvisasi dari performansi deteksi anomali sinyal, mengurangi ketidaksesuaian klasifikasi pengenalan sinyal normal yang terbaca tidak normal, dan memiliki kemampuan proses secara real time dengan waktu tunda yang kecil dan tingkat kompleksitas yang rendah [17]. Pengembangan arsitektur CNN 1 D telah dilakukan [18], untuk klasifikasi sinyal suara jantung, dengan kelebihan pada mekanisme spasial dan kanal. Model CNN yang diusulkan memiliki kemampuan untuk mengekstrak fitur penting dengan konsumsi parameter yang lebih rendah.

Untuk menjawab permasalahan yang ada seperti yang telah dipaparkan di atas, Berikutnya akan dilakukan penelitian awal tentang pengolahan sinyal pada Pasien serangan jantung yang dilakukan dengan pengolahan data PCG secara *real time*. Pemilihan data PCG ini didasarkan pada penelitian-penelitian sebelumnya yang berkaitan dengan deteksi sinyal normal dan abnormal dikarenakan murmur, baik murmur sistolik dan diastolik. Adanya sumbatan pada kasus MI menyebabkan aliran darah balik yang menyebabkan suara balik gemuruh namun tidak bisa didengarkan secara langsung menggunakan stetoskop, hal ini dikarenakan termasuk kategori “mikro murmur”. Murmur sistolik yang menyebabkan disfungsi otot papiler adalah fitur yang terkenal dari Acute Myocardial Infarction (AMI).

Penelitian ini akan mengeksplorasi ciri khusus saat pasien terkena serangan jantung, dan memproses klasifikasinya. Sehingga data yang diambil adalah dari data PCG dengan menggunakan ekspolarasi pengolahan sinyal untuk segmentasi, filtering, ekstraksi ciri dan klasifikasi untuk deteksi serangan jantung, mengacu pada penelitian-penelitian sebelumnya. Waktu yang dibutuhkan untuk pemasangan ECG sekitar dua menit, proses ini belum dihitung dengan proses pembacaan hasil grafik ECG yang juga membutuhkan waktu. Berdasarkan permasalahan dari uraian sebelumnya, penelitian ini berfokus pada pengembangan kecerdasan buatan Deep Learning untuk mendeteksi kondisi pasien bergejala MI menggunakan data PCG secara *real time*.

II. TINJAUAN PUSTAKA


A. Jantung

Jantung merupakan organ tubuh yang memiliki fungsi untuk memompa darah yang terdiri dari bagian atas disebut serambi (atrium) dan bagian bawah yang disebut dengan bilik (ventricle). Otot-otot jantung memompa darah dari satu ruangan ke ruangan lainnya, setiap kali terjadi proses pemompaan, katup jantung membuka sehingga darah dapat mengalir ke ruangan lain [19]. Otot jantung terdiri dari tiga bagian: 1. luar/ perikardium yang berfungsi sebagai pelindung jantung, 2. tengah/ miokardium merupakan otot jantung yang berfungsi menerima darah dari arteri koronaria tersusun dari tiga otot atria, ventrikuler dan atrioventrikuler. 3. Dalam/ Endokardium terdiri dari jaringan endotel. Detak jantung menghasilkan dua suara berbeda yang dapat didengarkan dengan stetoskop, seringkali dinyatakan dengan lub-dub. Suara lub disebabkan oleh penutupan katup triscupid dan mitral (atrioventrikular) yang memungkinkan aliran darah dari atrium (serambi jantung) ke ventricle (bilik


jantung) serta mencegah aliran balik biasanya disebut dengan suara jantung pertama (S1) yang terjadi pada awal systole (periode jantung berkontraksi).

Suara dub disebut suara jantung kedua (S2) yang terjadi pada akhir systole atau awal diastole dan disebabkan oleh penutupan katup semilunar (aortic dan pulmonary) yang membebaskan darah ke sistem sirkulasi paru-paru dan seluruh tubuh. Sinyal suara jantung merupakan sinyal gelombang suara yang lemah, dimana sinyal ini berada di-range antara 10 Hz hingga 250 Hertz [20]. Interval antara S1 dan S2 disebut dengan periode sistolik, dan interval antara S2 dan S1 disebut dengan periode diastolik. Satu siklus sinyal jantung memiliki rentang waktu 0.8 s [21]. Selain sinyal S1 dan S2 terdapat S3 (sinyal suara jantung diastolik awal), S4 (sinyal suara jantung diastolik akhir) dan murmur. S3 dan S4 terdapat pada kondisi normal, tetapi bisa terjadi pada kondisi patologis. Disisi lain murmur dipicu adanya struktur dan fungsi jantung yang cacat [22], yang disebut kondisi abnormal jantung. Gambar 1. menunjukkan dua siklus sinyal jantung normal dan Gambar 2. menunjukkan sinyal jantung tidak normal yang disebut dengan murmur sistolik awal terjadi pada kasus akut mitral regurgitasi. Murmur ini muncul sebagai panjang getaran yang terjadi selama periode sistolik karena aliran darah yang bergejolak melalui pembukaan yang sebagian terhambat katup mitral atau trikuspid.


Oleh karena itu, kehadiran murmur dalam suara jantung dapat menjadi indikasi kelainan pada jantung. Namun demikian, durasi dan lokasi murmur dapat bervariasi dari satu kasus ke kasus lain membuat sulit dan rumit untuk mengidentifikasi keberadaan murmur. Saat ini telah banyak penelitian tentang sinyal jantung ECG yang direkam pada kondisi jantung dengan kondisi telah mengalami serangan jantung. Gambar 3. merupakan sinyal normal ECG dan MI ECG dengan noise. Gambar 4. merupakan sinyal normal ECG dan MI ECG tanpa noise [23]. Gambar 5. merupakan simulasi terjadinya MI atau serangan jantung, karena penyumbatan arteri koroner. Arteri ini tersumbat dengan gumpalan darah juga dikenal sebagai trombus. Gumpalan darah ini terbentuk karena penumpukan plak di arteri. Penyumbatan lengkap aliran darah mengakibatkan serangan jantung dan menyebabkan otot jantung rusak.




Gambar. 1 Dua siklus sinyal jantung (PCG) normal [23].




Gambar. 2 Sinyal jantung (PCG) tidak normal dengan murmur sistolik awal [23].



Gambar. 3 Sinyal normal ECG dan MI ECG dengan noise [23]..



Gambar. 4 Sinyal normal ECG dan MI ECG tanpa noise [23]..



Gambar. 5 Ilustrasi MI atau serangan jantung [5].

B. Convolutional Neural Networks (CNN)

Deep Learning (DL) merupakan pencapaian terbaru dari Machine Learning yang memiliki kemampuan mendekati kemampuan manusia, dan telah diterapkan pada banyak aplikasi termasuk terjemahan suara-ke-teks, deteksi dan pengenalan objek, deteksi anomali, mengenali emosi dari rekaman audio atau video. Bahkan sebelum pengenalan AlexNet, telah terdapat artikel terobosan yang diterbitkan dalam jurnal, Science, pada tahun 2006 oleh Hinton dan Salakhutdinov, yang menjelaskan peran "kedalaman" dari ANN dalam pembelajaran mesin [24]. Hal ini menunjukkan bahwa ANN dengan beberapa lapisan tersembunyi dapat memiliki kemampuan belajar yang kuat dan dapat ditingkatkan dengan kedalaman yang meningkat atau setara dengan jumlah lapisan tersembunyi. Oleh karena itu muncul istilah pembelajaran "Mendalam", cabang ML tertentu, yang dapat mengatasi pola dan objek kompleks dalam dataset ukuran besar. Pada bagian ini, membahas dasar DL, CNN yang dalam (dan konvensional) serta menjelaskan fitur dan blok dasar. Selain itu, membahas secara singkat CNN dalam paling populer yang pernah diusulkan dan kemudian dilanjutkan dengan Arsitektur CNN terbaru, CNNs 1D, yang hanya berfokus pada sinyal 1D dan repositori data.

- CNN 2-D

Bagian ini memberikan gambaran singkat tentang conventional deep CNNs dan mengenalkan ide-ide paling mendasar serta arsitektur sebelumnya. Kelebihan:


a. CNNs memadukan ekstraksi fitur dan proses klasifikasi fitur menjadi satu badan pembelajaran untuk mengoptimalkan fitur selama fase pelatihan langsung dari input mentah.

b. Karena neuron CNN jarang terhubung dengan bobot terikat, CNN dapat memproses input besar dengan komputasi yang hebat lebih efisien dibandingkan dengan jaringan Multi-Layer Perceptrons (MLP) konvensional yang terhubung sepenuhnya.

c. CNNs tidak terpengaruh oleh transformasi kecil dalam data input termasuk translasi, penskalaan, kemiringan dan distorsi.

d. CNN dapat beradaptasi dengan ukuran input yang berbeda.

Dalam MLP konvensional, setiap neuron tersembunyi mengandung bobot skalar, input dan output. Namun, karena sifat 2D dari Gambar, setiap neuron dalam CNN mengandung 2-D untuk bobot, yang dikenal sebagai kernel, dan input dan output sebagai peta fitur.




Gambar. 6 CNN dengan dua konvolusi dan 1 layer terhubung penuh [25].

Gambar 6. menggambarkan blok dasar dari konfigurasi CNN sampel yang mengklasifikasikan 24 x 24 piksel gambar skala abu-abu menjadi dua kategori. Jaringan sampel ini terdiri dari dua konvolusi dan dua lapisan pooling dengan 4 dan 6 neuron. Output dari lapisan pooling terakhir diproses oleh satu lapisan yang terhubung sepenuhnya dan diikuti oleh lapisan output yang menghasilkan output klasifikasi. Interkoneksi konvolusi layer diberikan oleh filter bobot yang memiliki ukuran kernel (K_x, K_y). Konvolusi terjadi dalam batas-batas gambar; oleh karena itu, dimensi peta fitur dikurangi dengan ($K_x-1; K_y-1$) piksel dari lebar dan tinggi.

Subsampling faktor (S_x, S_y) diatur terlebih dahulu di lapisan pooling. Dalam contoh ilustrasi pada gambar, ukuran kernel sesuai ke dua lapisan konvolusi ditetapkan ke $K_x = K_y = 4$, sedangkan faktor subsampling ditetapkan sebagai $S_x = S_y = 3$ untuk pooling layer pertama dan $S_x = S_y = 4$ untuk yang kedua.

Nilai-nilai ini dipilih sehingga output dari yang terakhir Lapisan pooling (yaitu input ke lapisan yang sepenuhnya terhubung) adalah skalar. (1×1). Lapisan output terdiri dari dua sepenuhnya terhubung neuron sesuai dengan jumlah kelas yang dikategorikan gambar. Gambar 7. menunjukkan konfigurasi CNNs "LeNet" dengan sebuah input gambar.



Gambar. 7 Konfigurasi CNNs “LeNet” pada penelitian [25].

Terdapat dua layer konvolusi dan pooling layer, dengan dua layer tersembunyi dan satu output yang terdiri dari 10 Radial Basis Function (RBF) neurons yang masing-masing dihitung jarak Euclidean antara jaringan output dan ground truth untuk 10 kelas.

- CNN 1-D


CNN dalam konvensional yang dijelaskan di bagian sebelumnya dirancang untuk beroperasi pada data 2D seperti gambar dan video. Inilah sebabnya disebut sebagai, "CNNs 2D". Terdapat model modifikasi CNNs 2D yang disebut Convolutional Neural Networks (1D CNNs). Sebagai alternatif, versi modifikasi dari CNNs 2D disebut 1D Convolutional Neural Networks (1D CNNs) baru-baru ini dikembangkan [16] [26] [27] [28] [29] [30] [31] [32] [33]. Untuk aplikasi tertentu CNN 1D menguntungkan dan lebih baik daripada 2D dalam sinyal 1D.

Beberapa kelebihanannya:

- Kompleksitas komputasi 1D dan 2D konvolusi, yaitu, gambar dengan $N \times N$ dimensi yang konvolusi dengan kernel $K \times K$ akan memiliki kompleksitas komputasi $\sim O(N^2K^2)$ sedangkan dalam konvolusi 1D yang sesuai (dengan dimensi yang sama, N dan K) ini adalah $\sim O(NK)$. Ini berarti bahwa dalam kondisi yang setara (konfigurasi yang sama, jaringan dan parameter hiper) kompleksitas komputasi dari CNN 1D secara signifikan lebih rendah dari 2D CNN.
- Aplikasi CNN 1D telah menggunakan *compact* (dengan 1-2 lapisan CNN tersembunyi) konfigurasi dengan jaringan yang memiliki parameter $< 10^6$ K sedangkan hampir semua aplikasi CNN 2D memiliki menggunakan arsitektur "dalam" dengan parameter lebih dari 1 M (biasanya di atas 10 M).
- Pelatihan CNN 2D yang “dalam” membutuhkan pengaturan perangkat keras khusus (misalnya cloud computing atau GPU). Dilain pihak Setiap implementasi CPU melalui komputer standar relatif cepat untuk melatih CNNs 1D *compact* dengan sedikit lapisan tersembunyi (misalnya 2 atau kurang) dan neuron (misalnya < 50).
- Karena persyaratan komputasinya yang rendah, CNN 1D *compact* sangat cocok untuk aplikasi *real-time* dan berbiaya rendah terutama pada perangkat *mobile*.

Aplikasi pertama CNN 1D pada identifikasi detak jantung ECG [34] dimana solusi “pasien-khusus” telah diusulkan untuk masing-masing pasien aritmia dikhususkan untuk CNN 1D yang telah ditraining menggunakan data training pasien khusus dengan tujuan mengidentifikasi masing-masing detak jantung ECG kedalam lima kelas yaitu: N (*beats originating in the sinus mode*), S (*supraventricular ectopic beats*), V (*ventricular ectopic beats*), F (*fusion beats*), and Q

(*unclassifiable beats*). Gambar 8. merupakan contoh CNN 1D dengan 3 layer CNN dan 2 layer MLP.



Gambar. 8 Contoh CNN 1 D [25].

Perbedaan utama antara CNNs 1D dan 2D, di mana 1D Array menggantikan matriks 2D untuk kernel dan peta fitur. Sebagai langkah selanjutnya, lapisan CNN memproses data 1D mentah dan mengekstrak fitur yang digunakan dalam tugas klasifikasi yang dilakukan oleh lapisan MLP. Hal ini merupakan kelebihan utama dari CNN 1D yang juga dapat menghasilkan kompleksitas komputasi yang rendah. Karena satu-satunya operasi dengan biaya yang signifikan adalah urutan konvolusi 1D yang merupakan penjumlahan linier bobot dua array 1D. Operasi linier tersebut dapat dieksekusi secara efektif dan paralel selama Forward dan Back-Propagation.

Forward- dan back-propagation pada CNN:

Masing-masing layer CNN, 1D forward propagation (1D-FP) memiliki persamaan:

$$x_k^l = b_k^l + \sum_{i=1}^{N_{l-1}} \text{conv1D}(w_{ik}^{l-1}, s_i^{l-1}) \quad (1)$$

x_k^l didefinisikan sebagai input, b_k^l merupakan bias dari k^{th} neuron pada layer l , s_i^{l-1} adalah output dari i^{th} neuron pada layer $l - 1$, w_{ik}^{l-1} adalah kernel dari i^{th} neuron pada layer $l - 1$ sampai k^{th} neuron pada layer l . Konvolusi 1 D (...) digunakan untuk menampilkan hasil yang valid konvolusi 1D tanpa zero-padding. Oleh karena itu, dimensi dari input array x_k^l dimensinya kurang dari dimensi output array s_i^{l-1} . Output menengah y_k^l dapat ditunjukkan melalui input x_k^l yang melewati fungsi aktivasi $f(\cdot)$ sebagai:

$$y_k^l = f(x_k^l) \text{ dan } s_k^l = y_k^l \downarrow ss \quad (2)$$

dimana s_k^l merupakan output ke k^{th} neuron layer l dan $\downarrow ss$ merepresentasikan downsampling dengan faktor skalar, ss .

Algoritma Back-propagation (BP), dapat disimpulkan sebagai berikut: *back propagating error* mulai dari layer output MLP. Diasumsikan bahwa $l = 1$ untuk input layer dan $l = L$ untuk layer output. N_L jumlah dari kelas di database, input vektor p , target dan vektor output t^p dan $[y_{1,...,N_L}^L]^T$. Dengan demikian, layer output E_p untuk input p ; merupakan hasil Mean Squared Error (MSE), dengan persamaan:

$$E_p = \text{MSE}(t^p, [y_{1,...,N_L}^L]^T) = \sum_{i=1}^{N_L} (y_i^L - t_i^p)^2 \quad (3)$$

C. Long Short Term Memory Neural Network (LSTM)

Long Short Term Memory (LSTM) [49] terdiri dari blok memori yang terhubung sebagai bagian dari Recurring Neural Network (RNN) dan digunakan dalam jaringan saraf tiruan. Setiap memori blok di LSTM berisi tiga gerbang, input, output dan forget yang melakukan operasi fungsi “membaca”, “menulis” dan “reset”. Lebih tepatnya, input sel dikalikan dengan gerbang input. Output dari sel dikalikan dengan gerbang output dan nilai sel sebelumnya dikalikan dengan gerbang forget.

Blok LSTM pada Gambar 9. terdiri dari beberapa jumlah gerbang; yaitu input (i), output (o), dan forget (f) gerbang. Gerbang ini bertindak sebagai blok memori ke sel fungsional utama untuk menyimpan aktivasi input dan output serta menghitung proporsi data yang akan disimpan dalam memori jaringan, masing-masing. Nilai output C pada waktu ke t didefinisikan dengan persamaan [35]:

$$C_t = f_t C_{t-1} + i_t c_t \quad (4)$$

Dimana f_t adalah aktivasi forget gate, i_t merupakan aktivasi input gate, dan c_t input pada sel utama. Jaringan memiliki aktivasi unit tersembunyi berdasarkan fungsi sigmoid $\sigma(\cdot)$ dengan persamaan:

$$h_t = o_t \tanh(c_t) \quad (5)$$

dimana o_t merupakan aktivasi gate output.

Keluaran dari sigmoid adalah angka 1 atau 0 yang menandakan informasi tersebut akan dipertahankan atau dibuang. Angka 0 menandakan tidak ada informasi yang akan dipertahankan, sedangkan angka 1 menandakan semua informasi akan dipertahankan. LSTM akan memutuskan informasi apa yang akan dibuang dari *cell state* yang diproses oleh sigmoid layer.

Masing-masing gate dirumuskan:

$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci}c_{t-1} + b_i) \quad (6)$$

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf}c_{t-1} + b_f) \quad (7)$$


$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co}c_{t-1} + b_o) \quad (8)$$

$$c_t = \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \quad (9)$$

Dimana W_{x*} merupakan bobot input ke gate, W_{h*} bobot hidden ke hidden dan W_{c*} bobot peephole. Model yang digunakan pada literatur studi ini adalah LSTM (BiLSTM) yang memperbolehkan pemrosesan data dengan maju dan mundur selama proses pelatihan. BiLSTM didefinisikan:

$$y_t = W_{\bar{h}y}h^{\bar{N}} + W_{hy}h^N + b_y \quad (10)$$

dimana $h^{\bar{N}}$ dan h^N merupakan output hidden layer maju dan mundur untuk semua level N .




Gambar. 9 Struktur LSTM [49].

Semua LSTM layer dihubungkan dengan *softmax function* dengan rumus fungsi:

$$\text{softmax}(x_i) = \frac{\exp(x_i)}{\sum_i \exp(x_i)} \quad (11)$$

Bidirectional Long Short – Term Memory Neural Network (BiLSTM) merupakan salah satu varian dari *Long Short Term Memory* yang paling sering digunakan. Input *forward* dan input *backward* adalah 2 jenis masukan yang dimasukkan ke dalam arsitektur *Bidirectional Long Short Term Memory*. Output dari arsitektur ini biasanya digabungkan jadi satu. Dengan layer arsitektur ini, model bisa menjalankan data masa lalu (*past*) dan data masa mendatang (*future*) untuk setiap sekuen input.



Gambar. 10 Arsitektur BiLSTM [49].

Bidirectional LSTM memanfaatkan informasi sebelumnya dan informasi setelahnya dengan memproses data dari dua arah. Forward layer berfungsi untuk merepresentasikan informasi sebelumnya, dan backward layer berfungsi untuk merepresentasikan informasi setelahnya.

Pada Gambar 10. bisa dilihat dari setiap hidden layer keluaran unit pada layer bawah dan atas disatukan hingga membentuk nilai fitur yang lebih panjang dari pada LSTM biasa. Karena nilai fitur pada BiLSTM lebih panjang, maka informasi yang akan diproses pada proses selanjutnya yaitu feed forward neural akan mengklasifikasikan dengan lebih detail.

Dengan adanya *hidden layer* dua arah ini yang saling berlawanan maka model dapat memahami data dari depan dan belakang, sehingga proses pelatihan akan lebih memahami data pada *time series*. BiLSTM akan sangat berguna dalam hal pelatihan sekuensial apabila bisa

mengakses dari informasi sebelum dan sesudahnya. Jika LSTM hanya bisa mengakses informasi dari masa lalu saja, tetapi informasi masa mendatang tidak diketahui. BiLSTM bisa menjadi solusi untuk memecahkan masalah tersebut. Pada studi literatur ini, selain yang telah dijabarkan pada pemaparan sebelumnya terdapat tiga tabel, yaitu Tabel 1 merupakan Hasil rangkuman review paper tentang Deteksi MI, menggunakan sinyal ECG dengan variasi ekstraksi fitur dan classifier. Tabel 2 merupakan Hasil Rangkuman studi literatur klasifikasi otomatis sinyal normal dan abnormal pada PCG menggunakan model Deep Learning.

TABEL 1. RANGKUMAN REVIEW PAPER MI

Peneliti, Tahun	Jumlah Lead	Fitur	Jumlah detak	Pengklasifikasi	Kinerja
Lahiri et al., 2009 [36]	12 lead	Deteksi puncak R Fase ruang fractal	Dimensi ECG 64,680 Puncak R dari 1848	Artificial neural network	Eff = 96.00%
Banerjee et al., 2012 [37]	lead III	Deteksi puncak R Transformasi Cross wavelet Teknik koherensi Wavelet	Normal: 1 148 MI pasien	-	Pola EKG menggambarkan perbedaan yang berbeda antara R1 dan R2
Arif et al., 2012 [38]	12 lead	Deteksi ciri QRS domain waktu	Normal: 3200 MI: 16,960	k-nearest neighbor	Sen = 99.97% Spec = 99.90%
Sharma et al., 2015 [39]	12 leads	Wavelet transform Multiscale energy Analisis Multiscale eigenspace	549 records	Support vector machine	Acc = 96.00% Sen = 93.00% Spec = 99.00%
Acharya et al., 2016 [40]	12 leads	Deteksi puncak R Deteksi MI dengan 47 fitur Lokalisasi MI 25 fitur	Normal: 125,652 MI: 485,753	k-nearest neighbor	Acc = 98.80% Sen = 99.45% Spec = 96.27%
Acharya et al., 2017 [41]	lead II	Deteksi puncak R 11-layer deep neural network Tidak ada fitur seleksi dan reduksi. Denoising tidak diperlukan	Normal: 10,546 MI: 40,182	Convolutional neural network	dengan noise: Acc = 93.53% Sen = 93.71% Spec = 92.83% tanpa noise: Acc = 95.22% Sen = 95.49% Spec = 94.19%

*) Acc = akurasi, Sen = sensitivitas, dan Spec = spesifisitas

TABEL 2. RANGKUMAN REVIEW PAPER PCG

Peneliti, Tahun	Metode	Sampel	Kinerja
Potes et al, 2016, [42]	Pengklasifikasi CNN Ensemble	Normal: 2575 bentuk gelombang PCG Abnormal: 665	Acc: 85% Spec: 82% Sen: 88%

	Dekomposisi sinyal menjadi 4 band frek	bentuk gelombang PCG	
Yang et al., 2016, [43]	Recurrent neural network Teknik cross validation	420000 Sampel	Acc: 84%
Maknickas et al 2017, [44]	CNN 256 hidden layer	4430 Sampel	Training Acc: 99.7% Validation Acc: 95.2%
Rubin et al, 2017, [45]	Segmentasi sinyal Sinyal tersegmentasi ditransformasi ke heat maps CNN ditraining menggunakan heat maps	Testing data: 301 PCG (bentuk gelombang PCG) Training data: 2852 PCG (bentuk gelombang PCG)	Acc: 83.9% Spec: 95.2% Sen: 72.7%
Nasralla et al , 2017, [46]	Segmentasi menggunakan logistic regression hidden semi Markov model. (bentuk gelombang PCG) Ciri Frekuensi waktu Deep Neural Network (15 layers)	Normal dan Abnormal = 3126	Acc: 92% Spec: 98% Sen: 78%
Latif et al, 2018, [47]	Pra pemrosesan S1 dan S2 Segmentasi sinyal Seleksi fitur menggunakan Mel frequency cepstral coefficient Klasifikasi menggunakan	Normal dan Abnormal = 3240	Acc: 97.1% Spec: 96.7% Sen: 99.9%

	ulkan LSTM, bi-LSTM models		
Bozkurt et al, 2018, [48]	CNN Sub band fitur envelope	Innocent murmur: 336 Recordings (327 anak-anak) abnormal murmur: 130 Recordings (117 anak-anak)	Acc: 84.5% Spec: 78.5% Sen: 81.5%
Dominguez-Morale, 2018 [49]	Pra pemrosesan dan disegmen tasi menggunakan ueromorph ic auditory sensor Modifikasi AlexNet model untuk performansi terbaik CNN	Normal dan abnormal = 3126	Acc: 97% Spec: 95.12%
Raza et al. 2019 [50]	Ciri Spektrogram RNN-LSTM	Normal 320 Murmur 95 Extra-systole 46	Acc: 80.8%
Alkhodari et al (2021) [35]	CNN-BiLSTM	9,600 Sampel	Co-hen's kappa: 97.87 % Acc: 99.32 % Sen: 98.30 % Spec: 99.58 %

*) Acc = akurasi, Sen = sensitivitas, dan Spec = spesifisitas

III. KLASIFIKASI SINYAL SUARA JANTUNG MENGGUNAKAN DEEP LEARNING

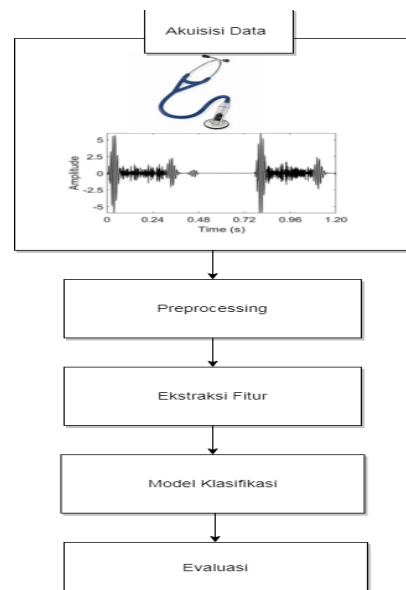
Pentingnya sistem pendukung keputusan tentang hasil sinyal suara jantung saat terjadi serangan jantung, membuat proses klasifikasi harus tepat dan *real time*. Saat terjadi serangan jantung suara yang dihasilkan tidak dapat didengarkan secara langsung karena tergolong "mikro murmur", untuk itu beberapa tahapan awal penelitian ini adalah melakukan tahapan Pra pemrosesan seperti halnya penelitian tentang pemisahan suara jantung normal dengan murmur yang menjadi landasan penelitian ini. Kecepatan pemrosesan pengambil keputusan, daya konsumsi yang dibutuhkan oleh komputer. CNN-1D diusulkan sebagai metode untuk klasifikasi sinyal PCG yang efektif [18]. Penelitian tentang membedakan tiga kategori: Normal, murmur dan ekstra sistolik, dengan menerapkan Deep Learning menghasilkan akurasi 80%. Terdapat proses downsampling, pemfilteran dan proses klasifikasi menggunakan Recurrent Neural Network (RNN) berbasis Long Short-Term Memory (LSTM), Dropout, Dense and Softmax layer. Gambaran penelitian ditunjukkan pada Gambar 11. merupakan Gambaran Penelitian Deteksi Heart Attack pada Sinyal PCG.

A. Pra pemrosesan

Pada tahap ini Sinyal suara jantung terlebih dahulu dilakukan filtering dengan bandpass [50]. Diolah dengan frekuensi sampling 4kHz. Selanjutnya dilakukan data framing supaya sinyal suara memiliki panjang perekaman yang sama pada beberapa penelitian dipotong menjadi 12.5 s frame rate, terdapat pula penelitian dengan menerapkan frame rate 10 s [21].

B. Down-Sampling

Proses down sampling ini digunakan untuk membantu mengurangi frekuensi sinyal yang mempunyai pengaruh minor. Pengurangan frame rate menggunakan downsampling ini memiliki tujuan mengekstrak ciri diskriminasi. Sehingga ciri yang terpilih yang akan masuk sebagai input dan digunakan pada klasifikasi.



Gambar. 11 Gambaran umum penelitian

C. Metode yang diusulkan

Metode arsitektur RNN diaplikasikan pada penelitian ini meliputi berbagai layer input, LSTM, Dropout, Dense and Softmax layer. Pada dense layer terdapat bentuk perkalian matrik yang mencerminkan jumlah kelas. Misalkan pada penelitian ini klasifikasi dibedakan: normal, Steady Coronary, MI STEMI dan MI Non STEMI.

LSTM: The Long Short-Term Memory terdiri dari blok yang terhubung sebagai memori blok yang merupakan bagian dari RNN. Masing-masing blok memori terdiri dari 3 gates, input dan output dan forget yang memiliki operasi berbeda. Input dari sel dikali dengan input dari gate. Output dari sel dikali dengan output dari gate. Output sel dikalikan dengan output gate dan nilai sel sebelumnya dikali dengan forget gate.

Dropout Layer: Overfitting merupakan masalah besar pada machine learning. Berbeda dengan algoritma klasifikasi training data yang memberikan hasil memuaskan. Kemudian

diaplikasikan pada data yang hasilnya tidak memuaskan. Ini terjadi ketika dua atau lebih neuron mendeteksi hasil yang sama berulang-ulang dan perlu mengedrop neuron yang tidak berdampak pada hasil.

Dense Layer:

Lapisan satu set neuron yang mendapatkan input sebagai berat, melakukan beberapa fungsi linier, output ke lapisan berikutnya. Dense layer adalah jaringan saraf paling dasar dalam pembelajaran mendalam yang digunakan untuk mengubah dimensi lapisan.

$$X = f(Y \cdot w + b) \quad (12)$$

X adalah output layer, Y input layer, w adalah bobot, f fungsi aktivasi b vektor bias.

Softmax Layer:

Fungsi aktivasi yang penting pada deep learning yang berfungsi memutuskan neuron aktif atau tidak. Sebuah fungsi yang efektif dalam mengatasi klasifikasi multi kelas.

Evaluasi [35]:

Confusion matrix adalah suatu metode yang dapat digunakan untuk pengukuran, adapun penjelasannya, yaitu : Po merupakan Persentase jumlah pengukuran yang konsisten antar rater.

Pc merupakan Persentase jumlah pengukuran yang konsisten antar rater.

Nilai Kappa antara 1 sampai dengan -1.

TP merupakan hasil dari prediksi yang positif dan sesuai dengan target yang sesungguhnya positif.

TN merupakan hasil dari prediksi yang negatif dan sesuai dengan target yang sesungguhnya negatif.

FP merupakan hasil dari prediksi yang sesungguhnya positif, namun hasil targetnya negatif.

FN merupakan hasil dari prediksi yang sesungguhnya negatif, namun hasil targetnya positif.

Confusion Matrix Cohen's Kappa:

$$k = \frac{Po - Pc}{1 - Pc} \quad (13)$$

Rumus Akurasi:

$$\text{Akurasi} = \{TP + TN\} / \{TP + TN + FP + FN\} \quad (14)$$

Rumus Precision / Post Predictive Value:

$$PPV = \{TP\} / \{TP + FP\} \quad (15)$$

Rumus Specificity:

$$\text{Specificity} = \{TN\} / \{TN + FP\} \quad (16)$$

Rumus F1-Score:

$$F1\text{-Score} = \{2 \times TP\} / \{2 \times TP + FP + FN\} \quad (17)$$

IV. TANTANGAN DAN PELUANG PENELITIAN

A. Tantangan

- Arsitektur Jaringan

Pemilihan arsitektur jaringan syaraf sangat berpengaruh terhadap hasil yang didapatkan. Tidak hanya itu model dan variasi yang digunakan pada pemrosesannya adalah hal yang butuh dipertimbangkan secara tepat baik dari segi pemrosesan komputasi maupun hasilnya. Pada penerapan Convulusi 1-D untuk deteksi anomali sinyal PCG secara *real time*. Hal ini dipilih untuk mengurangi kesalahan deteksi dan juga untuk mengurangi kompleksitas komputasi [17]. Deep Neural Network (CNN-BiLSTM) untuk secara otomatis mengekstrak hubungan spasial dan waktu pada sinyal. Ekstraksi fitur dilakukan pada proses training [35]. Penelitian ini digunakan

untuk mendeteksi penyakit katub jantung pada perekaman sinyal suara jantung.

- Optimasi hyperparameter

Parameter ini merupakan parameter penting untuk mendapatkan hasil yang maksimal. Optimasi ini di setting sebelum dilakukan proses training. Konfigurasi pada parameter ini bergantung pada jenis data, jumlah data dan tujuan yang ingin dicapai. Beberapa pengaturan tentang hyperparameter antara lain: panjang filter, jumlah hidden layer, dan learning rate sangat berpengaruh pada hasil akhir. Oleh karena itu pengetahuan awal tentang fungsi masing-masing sangatlah penting terutama untuk sinyal yang dinamis seperti sinyal biologis.

- Imbalance dataset

Keseimbangan dalam dataset sangatlah penting dalam proses pengolahan data. Berfokus pada mengubah data mentah menjadi informasi yang dapat digunakan sebelum dianalisis. Penyesuaian data menjadi distribusi normal membutuhkan waktu dalam pemrosesannya. Sehingga perlu dicermati data yang diolah sudah balance atau belum.

- Proses Ekstraksi Ciri

Hal yang tidak bisa dihindari dalam pemrosesan sinyal adalah pemilihan ciri yang tepat untuk menentukan sebuah klasifikasi. Pemilihan fitur yang kurang tepat akan menyebabkan proses pembelajaran pada Machine Learning tidak mendapatkan hasil yang maksimal.

B. Peluang Penelitian

- Pemodelan Klasifikasi Pada Sinyal Medis

Terdapat berbagai penemuan penelitian yang menyebabkan beberapa model selalu diunggulkan. Pemodelan pada sinyal medis bukanlah hal yang mudah, hal ini dikarenakan sinyal yang dinamis dan memiliki karakteristik yang unik pada setiap jenisnya. Pengetahuan yang luas akan karakter sinyal akan sangat mempengaruhi gaya pemodelan yang dipilih, tentunya hal ini juga mengacu dari tujuan akhir yang ingin dicapai.

- Mengintegrasikan beberapa jenis data ekstraksi ciri

Ekstraksi ciri merupakan tahapan penting pada pemrosesan sinyal. Dimana hasil dari ekstraksi ciri ini akan menjadi inputan pada Machine Learning. Semakin detail dan tepat ciri yang diintegrasikan, maka hasil yang didapatkan pada proses klasifikasi akan maksimal. Berbagai metode ekstraksi ciri memberikan keunggulan dan kelemahannya. Pemilihan hasil ekstraksi dan pemrosesannya harus dilakukan dengan tepat. Ekstraksi ciri yang berbeda akan memberikan hasil yang berbeda pula. Hal inilah yang menjadi peluang untuk penelitian, dimana ekstraksi ciri bisa dilakukan dengan kompleksitas rendah namun memberikan hasil yang tepat.

- Pemilihan Filter

Proses perekaman sinyal biomedis melibatkan banyak hal antara lain: keahlian dalam perekaman, pergeseran stetoskop mengakibatkan suara tambahan pada perekaman sinyal suara jantung, selain itu kondisi lingkungan yang bising mempengaruhi hasil rekaman. Untuk itu dibutuhkan tidak hanya filter dari perangkat keras namun filter dari pengolahan

sinyal juga sangat penting. Seperti pada perekaman sinyal jantung, frekuensi listrik 50 Hz juga akan masuk dalam range sinyal 20-200 Hz.

V. KESIMPULAN

Proses deteksi heart attack (MI) sinyal suara jantung memerlukan beberapa tahapan proses diantaranya adalah proses akuisisi data, dimana pada penelitian ini data primer akan diambil dari Pasien Rumah Sakit. Proses selanjutnya setelah akuisisi data adalah preprocessing, pada tahapan ini terdapat proses filtering untuk menghilangkan noise yang terdapat saat pengambilan perekaman sinyal suara jantung. Setelahnya berbagai jenis filter akan dibandingkan hasilnya. Setelah filtering berikutnya adalah proses segmentasi sinyal. Hal ini digunakan untuk mereduksi jumlah sample sebelum dilakukan ekstraksi ciri. Bagian penting lainnya adalah mencari informasi penting pada sinyal suara jantung dengan mencari fitur-fitur yang tepat sebagai inputan kecerdasan buatan. Penerapan Deep Learning pada penelitian ini memiliki harapan besar untuk dapat mengklasifikasi heart attack dengan tepat dan efektif sehingga kedepannya sistem ini mampu diterapkan pada *wearable device*.

REFERENCES

- [1] P. Nag, S. Mondal, F. Ahmed, A. More and M. Raihan, "Simple acute myocardial infarction (Heart Attack) prediction system using clinical data and data mining techniques," in *20th International Conference of Computer and Information Technology (ICCIT) IEEE*, 2017.
- [2] D. Rahmat, A. A. Putra and A. W. Setiawan, "Heart Disease Prediction Using K-Nearest Neighbor," in *International Conference on Electrical Engineering and Informatics (ICEEI): IEEE*, Kuala Terengganu, Malaysia, 2021.
- [3] U. R. Acharya, H. Fujita, V. K. O. S. L. Sudarshan, M. Adam, J. E. Koh and R. San Tan, "Automated detection and localization of myocardial infarction using electrocardiogram: a comparative study of different leads," *Elsevier (Knowledge-Based Systems)*, vol. 99, pp. 146-156, 2016.
- [4] J. Vomlel, H. Kruzík, P. Tuma, J. Precek and M. Hutýra, "Machine learning methods for mortality prediction in patients with st elevation myocardial infarction. Proceedings of WUPES, 2012, 204-213.," in *Proceedings of WUPES*, 2012.
- [5] U. R. Acharya, H. Fujita, S. L. Oh, Y. Hagiwara, J. H. Tan and M. dam, "Application of deep convolutional neural network for automated detection of myocardial infarction using ECG signals," *Information Sciences*, vol. 415, pp. 190-198, 2017.
- [6] S. B. Patil and Y. S. Kumaraswamy, "Extraction of significant patterns from heart disease warehouses for heart attack prediction," *IJCSNS*, vol. 9, no. 2, pp. 228-235, 2009.
- [7] M. E. Asl, M. Rahimpour, M. R. Merati, A. H. Panahi and K. Gholami, "Pre-Hospital Management of Acute Myocardial Infarction Using Tele-Electrocardiography System," Cornell University, 2018.
- [8] S. R. N and J. Arif, "Acute Myocardial Infarction (MI)," Merck Sharp & Dohme Corp, Northwestern, 2021.
- [9] S. R. Thiyagaraja, R. Dantu, P. L. Shrestha, A. Chitnis, M. A. Thompson, P. T. Anumandla and S. Dantu, "A novel heart-mobile interface for detection and classification of heart sounds," *Biomedical Signal Processing and Control*, vol. 45, pp. 313-324, 2018.
- [10] M. Z. Suboh, M. Yaakop, M. S. A. R. Ali, M. Y. Mashor, A. R. M. Saad, M. A. Abu and A. F. Ramli, "Portable heart valve disease screening device using electronic stethoscope," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 15, no. 1, pp. 122-132, 2019.
- [11] C. S. Potes, "Ensemble of Feature-based and Deep learning-based Classifiers for Detection of Abnormal Heart," *Computing in Cardiology*, pp. 621-624, 2016.
- [12] K. P. Sujadevi, "Anomaly Detection in Phonocardiogram Employing Deep Learning," *Springer Nature Singapore*, pp. 525-534, 2019.
- [13] F. F. Firuzbakht, "Abnormal Heart Sound Diagnosis based on Phonocardiogram Signal Processing," in *26th Iranian Conference on Electrical Engineering (ICEE2018), IEEE*, 2018.
- [14] R.S. Remya, K.P. Indiradevi, K.K. Anish Babu, "Classification of Myocardial Infarction Using Multi Resolution Wavelet Analysis of ECG," *Procedia Technology*, vol. 4, p. 949-956, 2016.
- [15] X. Chen, W. Guo, L. Zhao, W. Huang, L. Wang, A. Sun and F. Mo, "Acute Myocardial Infarction Detection Using Deep Learning-Enabled Electrocardiograms," *Cardiovascular Medicine*, vol. 8, 2021.
- [16] T. I. M. G. S. Kiranyaz, "Real-time patient-specific ECG classification by 1-D convolutional neural networks," *IEEE Trans. Biomed. Eng.*, vol. 63, p. 664-675, 2016.
- [17] S. Kiranyaz, M. R. A. B. Zabihi, T. Ince, R. Hamila and M. Gabbouj, "A. Real-time phonocardiogram anomaly detection by adaptive 1D convolutional neural networks," *Neurocomputing*, vol. 411, pp. 291-301, 2020.
- [18] B. Xiao, Y. Xu, X. Bi, J. Zhang and X. Ma, "Heart sounds classification using a novel 1-D convolutional neural network with extremely low parameter consumption," *Xiao, B., Xu, Y., Bi, X., Zhang, J., & Ma, X. (2020). Heart sounds classification using a noNeurocomputing*, vol. 392, pp. 153-159, 2020.
- [19] I. G. Suarjaya, "Pengolahan Dan Visualisasi Data Sinyal Auskultasi Jantung Pada Android," *JCONES*, 2016.
- [20] A. T. Ekinasti, "Analisis Dan Ekstraksi Ciri Sinyal Suara Jantung Menggunakan Dekomposisi Wavelet," *JCONES*, 2016.
- [21] J. Jusak, I. Puspasari and W. I. Kusumawati, "A Semi-automatic Heart Sounds Identification Model and Its Implementation in Internet of Things Devices," *Advances In Electrical and Computer Engineering (AECE)*, vol. 21, no. 1, pp. 45-56, 2021.
- [22] J. H. Seo, H. Bakhshae, G. Garreau, C. Zhu, A. Andreou, W. R. Thompson and R. Mittal, "A method for the computational modeling of the physics of heart murmurs," *Journal of Computational Physics*, vol. 336, pp. 546-568, 2017.
- [23] M. Elhami Asl, M. Rahimpour, M. R. Merati, A. H. Panahi and K. Gholami, "Pre-Hospital Management of Acute Myocardial Infarction Using Tele-Electrocardiography System," *arXiv*, p. 1805, 2018.
- [24] G. E. Hinton and R. R. Salakhutdinov, "Reducing the dimensionality of data with neural networks," *Science*, vol. 313, no. 5786, pp. 504-507, 2006.
- [25] Y. LeCun, L. Bottou, Y. Bengio and Haffner, "Gradient-based learning applied to document recognition," *IEEE*, vol. 86, no. 11, pp. 2278-2324, 1998.
- [26] K. S, T. Ince, R. Hamila and G. M., "Convolutional Neural Networks for patient-specific ECG classification," *Proc. Annu. Int. Conf. IEEE Eng.*, 2015.
- [27] K. S, T. Ince and M. Gabbouj., "Personalized monitoring and advance warning system for cardiac arrhythmias," *Sci. Rep.*, vol. 7, 2017.
- [28] O. Avci, O. Abdeljaber, S. Kiranyaz and D. nman, "Structural damage detection in real time: implementation of 1D convolutional neural networks for SHM," in *Springer International*, 2017.
- [29] O. Abdeljaber, O. Avci, S. Kiranyaz, M. Gabbouj and I. D.J., "Real-time vibration-based structural damage detection using one-dimensional," *J. Sound Vib*, vol. 388, 2017.
- [30] O. Avci, O. Abdeljaber, S. Kiranyaz, B. Boashash, H. Sodano and I. D.J., "Efficiency Validation of One Dimensional Convolutional Neural Networks for Structural Damage Detection Using a SHM Benchmark Data," in *In Proc. 25th Int. Conf. Sound*, 2018.
- [31] O. Abdeljaber, O. Avci, S. Kiranyaz, B. B. H. Sodano and D. Inman, "1-D CNNs for structural damage detection: verification on a structural health monitoring benchmark data," *Neurocomputing*, 2017.
- [32] T. Ince, S. Kiranyaz, L. Eren, M. Askar and M. Gabbouj, "Real-time motor fault detection by 1-D convolutional neural networks," *IEEE Trans. Ind. Electron*, vol. 63, p. 7067-7075, 2016.
- [33] K. S, A. Gastli, L. Ben-Brahim, N. Alemadi and G. M, "Real-time fault detection and identification for MMC using 1D convolutional neural networks," *IEEE Trans. Ind. Electron*, 2018.

- [34] S. Kiranyaz, O. Avci, O. Abdeljaber, T. Ince, M. Gabbouj and D. J. Inman, "1D convolutional neural networks and applications: A survey," *Mechanical systems and signal processing*, vol. 151, 2021.
- [35] M. Alkhodari and L. Fraiwan, "Convolutional and recurrent neural networks for the detection of valvular heart diseases in phonocardiogram recordings," *Computer Methods and Programs in Biomedicine*, p. 200, 2021.
- [36] T. Lahiri, U. Kumar, H. Mishra, S. Sarkar and A. D. Roy, "Analysis of ECG signal by chaos principle to help automatic diagnosis of myocardial infarction," *Journal of Scientific & Industrial Research*, vol. 68, pp. 866-870, 2009.
- [37] S. Banerjee and M. Mitra, "Cross wavelet transform based analysis of electrocardiogram signals," *Electronics and Computer Engineering*, vol. 1, no. 2, pp. 88-92, 2021.
- [38] M. Arif, I. A. Malagore and F. A. Afsar, "Detection and localization of myocardial infarction using k-nearest neighbor classifier," *Journal of medical systems*, vol. 36, no. 1, pp. 279-289, 2012.
- [39] L. N. Sharma, R. K. Tripathy and S. Dandapat, "Multiscale energy and eigenspace approach to detection and localization of myocardial infarction," *IEEE transactions on biomedical engineering*, vol. 62, no. 7, pp. 1827-1837, 2015.
- [40] M. Adam and Koh, "Automated detection and localization of myocardial infarction using electrocardiogram: a comparative study of different leads," *Knowledge-Based Systems*, vol. 99, pp. 146-156, 2016.
- [41] U. R. Acharya, H. Fujita, O. S. Lih, Y. T. J. H. Hagiwara and M. Adam, "Automated detection of arrhythmias using different intervals of tachycardia ECG segments with convolutional neural network," *Information sciences*, vol. 405, pp. 81-90, 2017.
- [42] C. Potes, S. Parvaneh, A. Rahman and B. Conroy, "Ensemble of feature-based and deep learning-based classifiers for detection of abnormal heart sounds," *IEEE*, pp. 621-624, 2016.
- [43] T. C. I. Yang and H. Hsieh, "Classification of Acoustic Physiological Signals Based on Deep Learning Neural Networks with Augmented Features," *IEEE*, pp. 569-572, 2016.
- [44] V. Maknickas and A. Maknickas, "Recognition of normal–abnormal phonocardiographic signals using deep convolutional neural networks and mel-frequency spectral coefficients," *Physiological measurement*, vol. 38, no. 8, p. 1671, 2017.
- [45] J. Rubin, R. G. A. Abreu, S. M. I. Nelaturi and K. Sricharan, "Recognizing abnormal heart sounds using deep learning," *arXiv*, 2017.
- [46] M. Nassralla, Z. El Zein and H. Hajj, "Classification of normal and abnormal heart sounds," in *Fourth International Conference on Advances in Biomedical Engineering (ICABME) IEEE*, 2017.
- [47] S. Latif, M. Usman, R. Rana and J. Qadir, "Phonocardiographic Sensing Using Deep Learning for Abnormal Heartbeat Detection," *Sensors*, vol. 18, no. 22, pp. 9393-9400, 2018.
- [48] B. Bozkurt, I. Germanakis and Y. Stylianou, "A study of time-frequency features for CNN-based automatic heart sound classification for pathology detection," *Computers in biology and medicine*, vol. 100, pp. 132-143, 2018.
- [49] J. P. Dominguez-Morales, A. F. Jimenez-Fernandez, M. J. Dominguez-Morales and G. Jimenez-Moreno, "Neural Networks for the Recognition and Classification of Heart Murmurs Using Neuromorphic Auditory Sensors," *IEEE Transactions on Biomedical Circuit*, vol. 12, no. 1, pp. 24-34, 2017.
- [50] A. Raza, A. Mehmood, S. Ullah, M. Ahmad, G. S. Choi and B. W. On, "Heartbeat sound signal classification using deep learning," *Sensors*, vol. 19, no. 21, p. 4819, 2019.
- [51] N. S. Ranya and J. Arif, "Acute Myocardial Infarction (MI)," Merck Sharp & Dohme Corp., a subsidiary of Merck & Co., Inc., Kenilworth, NJ, USA, Northwestern , 2020.